

Pipeline actual del ETL de Estados Financieros de la CNV

Objetivo

El objetivo del proyecto es construir un pipeline completamente automático capaz de descargar y transformar todos los Estados Financieros publicados por la Comisión Nacional de Valores (CNV) Argentina en un dataset estructurado.

El resultado final será una base histórica propia de balances argentinos, almacenada en formato Parquet y lista para análisis financieros, screening de empresas, modelos cuantitativos y futuros productos de Catalaxia Finance.

¿Qué publica realmente la CNV?

La CNV no publica un archivo único con todos los balances.

Lo que existe es un sistema web compuesto por:

- Empresas
- Presentaciones realizadas por cada empresa
- Distintos tipos de documentos
- Estados financieros
- Comunicados
- Actas
- Nóminas
- Prospectos
- Informes varios

Los Estados Financieros son solamente una pequeña parte de todas esas presentaciones.

Por eso el principal desafío del proyecto fue descubrir cuáles documentos corresponden realmente a balances.

Pipeline completo

Paso 1 — Obtener todas las empresas

La CNV posee un endpoint denominado AutoComplete.

`https://www.cnv.gov.ar/SitioWeb/Empresas/AutoComplete`

Este endpoint devuelve todas las empresas registradas en la CNV.

Para cada empresa se obtiene información como:

- nombre
- CUIT
- ticker
- identificadores internos

Esta información se almacena en:

```
datos/empresas.csv
```

En la actualidad se obtienen aproximadamente **556 empresas**.

Paso 2 — Descubrir todas las presentaciones

Cada empresa posee una página pública:

```
https://www.cnv.gov.ar/SitioWeb/Empresas/Empresa/{CUIT}
```

Dentro del HTML de esa página aparecen todos los identificadores (GUID) de las presentaciones históricas realizadas por esa empresa.

Estos GUID identifican de manera única cualquier documento presentado ante la CNV.

Mediante una expresión regular se extraen todos esos GUID.

El resultado actual es aproximadamente:

```
79.772 presentaciones
```

Cada presentación queda registrada en:

```
datos/links.csv
```

Cada registro contiene:

- ticker
- empresa
- CUIT
- GUID
- URL pública

Hasta este punto todavía **no sabemos cuáles son balances**.

Paso 3 — Analizar cada presentación

Cada GUID puede abrirse mediante la URL:

```
https://aif2.cnv.gov.ar/presentations/publicview/{GUID}
```

Esta página contiene el documento presentado.

Durante la ingeniería inversa se descubrió que el HTML posee variables JavaScript extremadamente importantes.

Entre ellas:

```
presentationIdGlobal  
  
formTypeId  
  
formTypeName
```

Estos tres datos permiten identificar el tipo de documento sin necesidad de descargar archivos PDF.

Para cada presentación se extraen:

- presentationId
- formTypeId
- formTypeName

Paso 4 — Construcción del catálogo de formularios

Al analizar miles de documentos comenzaron a aparecer distintos tipos de formularios.

Por ejemplo:

- Estados Contables NIIF
- Estados Contables Comerciales
- Balance Consolidado
- Balance Subsidiaria
- Prospectos
- Nómina de Directores
- Hechos Relevantes
- Avisos
- Comunicados

Cada formulario posee un identificador propio (`formTypeId`).

Con esta información se construyó automáticamente un catálogo:

```
catalogo_formtypes.csv
```

El objetivo del catálogo es indicar cuáles formularios corresponden realmente a Estados Financieros.

Cada tipo queda marcado como:

```
es_eeff = 1
```

o

```
es_eeff = 0
```

Este catálogo evita tener que inspeccionar nuevamente miles de documentos en futuras ejecuciones.

Paso 5 — Filtrar únicamente los Estados Financieros

Una vez construido el catálogo, se realiza un cruce entre:

```
links.csv
```

y

```
catalogo_formtypes.csv
```

De esta forma se eliminan automáticamente todas las presentaciones que no son balances.

El resultado es un nuevo archivo:

```
links_eeff.csv
```

Este archivo contiene únicamente documentos financieros.

Actualmente existen aproximadamente:

```
5.400 Estados Financieros
```

correspondientes a las empresas ya analizadas.

Este número crecerá a medida que finalice el análisis de todos los GUID históricos.

Paso 6 — Descargar los HTML

Una vez identificados los Estados Financieros comienza la descarga real.

Para cada registro de:

```
links_eeff.csv
```

se realiza una solicitud HTTP a:

```
publicview/{GUID}
```

Cada documento descargado se valida automáticamente.

La validación verifica:

- HTML vacío
- errores internos
- mantenimiento
- captcha
- presencia de presentationId

Si el documento es válido se almacena localmente.

La estructura será:

```
eeff/  
  ALUA/  
    3523703.html  
  TXAR/  
  LEDE/  
  ...
```

El nombre del archivo no será el GUID.

Será el:

```
presentationId.html
```

porque es el identificador estable del documento.

Paso 7 — Auditoría automática

Una vez descargados los HTML comienza una etapa de análisis masivo.

Cada documento será inspeccionado automáticamente.

La auditoría detectará:

- cantidad de tablas HTML
- cantidad de filas
- cantidad de columnas
- scripts JavaScript
- blobs
- JSON embebido
- XML
- PDFs
- modelos de datos
- otros recursos presentes

El objetivo es comprender completamente cómo están contruidos los documentos de la CNV antes de desarrollar el extractor definitivo.

No se harán suposiciones sobre la estructura.

La auditoría se basa exclusivamente en los HTML reales descargados.

Paso 8 — Extracción de información financiera

Conociendo ya la estructura real de los documentos se implementará un extractor capaz de identificar automáticamente:

- Balance General
- Estado de Resultados
- Estado de Flujo de Caja
- Estado de Evolución del Patrimonio Neto
- Notas a los Estados Contables

El extractor deberá adaptarse a diferencias entre empresas y entre distintos años.

No se utilizarán reglas específicas para una empresa determinada.

El objetivo es que funcione con cualquier sociedad que publique información mediante la CNV.

Paso 9 — Normalización

Los datos extraídos de todos los documentos tendrán estructuras distintas.

Esta etapa unificará toda la información en un único modelo de datos.

Se resolverán diferencias como:

- nombres de cuentas
- formatos numéricos
- fechas
- monedas
- versiones de presentación
- cambios regulatorios

El resultado será una estructura uniforme para todas las empresas.

Paso 10 — Dataset final

Finalmente toda la información será almacenada en formato Parquet.

El pipeline completo producirá una base histórica similar a:

Empresa

↓

Ejercicio

↓

Balance

↓

Estado de Resultados

↓

Flujo de Caja

↓

Patrimonio Neto

↓

Notas

↓

Parquet

Este dataset será la base de Catalaxia Finance y podrá utilizarse para:

- análisis financiero
- indicadores
- valuación de empresas
- series históricas
- modelos cuantitativos
- machine learning
- APIs
- dashboards
- productos financieros futuros

Estado actual del proyecto

Actualmente se encuentran terminadas las etapas de:

- Descubrimiento de empresas.
- Descubrimiento de presentaciones.
- Clasificación automática de documentos.
- Identificación de Estados Financieros.

La siguiente etapa consiste en construir un descargador robusto que obtenga automáticamente todos los HTML de los Estados Financieros y sienta las bases para la extracción automática de la información contable.